Proyecto 3 · DarkWatch

Informe de avance · Semana 3 (Sprint 2: Testing + Iteración)

Interacción Hombre Máquina · Proyecto 3
Extensión de Chrome para detección de patrones oscuros con severidad, evidencia visual y clasificación local/remota segura

Grupo 4	Ariel Aguirre · Edwin Toapanta · Klever Lema
Fecha	20 de abril de 2026
Estado del sprint	MVP funcional ampliado con flujo local/remoto, severidad y validación manual preliminar
Versión revisada	Documento actualizado a partir de la plantilla compartida y del proyecto darkwatch-week3

Resumen ejecutivo

Durante la semana 3, DarkWatch se ha realizado testing e iteración. El sistema ahora clasifica hallazgos con severidad Alta/Media/Baja, genera evidencia visual automática del elemento detectado, compara cada caso con un catálogo ético interno inspirado en deceptive.design y fue probado en sitios reales para una validación manual preliminar de precisión.

1. Contexto del proyecto y criterio de la semana 3

El Sprint 2 de la semana 3 exige cuatro mejoras concretas sobre DarkWatch: incorporar severidad por patrón detectado, capturar automáticamente el elemento evidenciado, contrastar los hallazgos con un catálogo ético y realizar pruebas en cinco sitios distintos con validación de precisión. En esta iteración, la meta no fue solo “detectar algo”, sino demostrar que el flujo de análisis es más explicable, más seguro y mejor defendible durante la exposición del proyecto.

PROYECTO 3: DarkWatch — Detector de Patrones Oscuros

Dominio	Stack sugerido
Ética en diseño / Dark Patterns / UX crítica	JavaScript (Chrome Extension) + LLM API / Python + BeautifulSoup

Descripción

Extensión de navegador o aplicación web que analiza una página y detecta automáticamente patrones oscuros (dark patterns) de diseño: urgencia falsa, confirmshaming, suscripciones ocultas, etc. Conecta la ética en diseño con la ingeniería de software y el análisis con IA.

Semana 1 — Plan + Setup DevOps	▸ Investigar y catalogar 10 tipos de dark patterns ▸ Definir criterios de detección por tipo ▸ Configurar estructura de extensión Chrome (manifest v3) ▸ Crear repositorio con linting automático (ESLint)
Semana 2 — Sprint 1: MVP funcional	▸ Implementar captura de DOM de la página activa ▸ Enviar contenido al LLM para clasificación de dark patterns ▸ Mostrar panel con patrones detectados y su categoría ▸ Demo: analizar 5 e-commerce conocidos
Semana 3 — Sprint 2: Testing + Iteración	▸ Agregar severidad de cada patrón (Alto/Medio/Bajo) ▸ Captura de pantalla automática del elemento detectado ▸ Comparar resultados con catálogo ético (deceptive.design) ▸ Prueba con 5 sitios web distintos + validación de precisión
Semana 4 — Entrega Final + Demo	▸ Generar reporte exportable por sitio ▸ Publicar en Chrome Web Store (o build empaquetado) ▸ Presentación: demo en vivo + discusión ética de hallazgos ▸ Documentar falsos positivos y limitaciones

ENTREGABLE FINAL: Extensión de Chrome instalable + base de datos de 20 sitios analizados + reporte ético comparativo

Figura 1. Extracto del documento del módulo donde se define el Proyecto 3: DarkWatch y los objetivos de la semana 3.

2. Objetivo del sprint y alcance implementado

El objetivo del sprint fue extender el MVP de la semana anterior hacia una versión más robusta para pruebas, manteniendo el análisis local pero añadiendo un backend remoto seguro, sin exponer credenciales dentro de la extensión. El alcance efectivamente implementado puede resumirse en los siguientes puntos:

- clasificación de hallazgos con severidad Alta, Media o Baja;
- recorte automático del primer elemento detectado para generar evidencia visual dentro del popup;
- mapeo de cada hallazgo contra un catálogo ético interno almacenado en data/ethical-catalog.json;

- selector de motor de análisis Local/Remoto y endpoint configurable para backend Python;
- fallback al análisis local cuando el backend no está disponible o falla durante la clasificación;
- interfaz de resultados con resumen, badge de riesgo, conteo del DOM, referencia ética y lista de hallazgos.

2.1 Mapa de archivos principales incluidos

Archivo	Responsabilidad	Comentario relevante
manifest.json	Define la extensión MV3	Declara permisos activeTab y storage, popup y content scripts.
content.js	Captura snapshot de la página	Obtiene texto, conteos del DOM, hallazgos heurísticos y coordenadas visibles.
rules/detectors.js	Motor heurístico base	Asigna id, categoría, severidad y referencia ética para cada patrón.
services/llmClient.js	Puente local/remoto	Decide si la clasificación se ejecuta localmente o mediante endpoint remoto.
popup.js / popup.html	Interfaz del usuario	Presenta resumen, riesgo, hallazgos y recorte automático de evidencia.
data/ethical-catalog.json	Catálogo ético interno	Relaciona patrones como urgency, scarcity, hidden costs y obstruction.
backend/app.py	Endpoint FastAPI (documentado)	El backend fue reducido por seguridad, pero la arquitectura y el uso remoto quedan documentados en la evidencia y el README.

3. Arquitectura general y flujo de análisis

La arquitectura de DarkWatch en esta semana funciona en cuatro etapas. Primero, el content script captura un snapshot de la página activa y resume señales del DOM. Segundo, rules/detectors.js genera hallazgos heurísticos con id, categoría, severidad, evidencia textual y rectángulo visible del elemento. Tercero, services/llmClient.js decide si la clasificación final se mantiene en modo local o si envía el snapshot al backend remoto. Finalmente, el popup consolida los resultados y muestra el nivel de riesgo, la evidencia ética y el recorte visual del hallazgo prioritario.

Página activa → **Snapshot DOM** → **Reglas + LLM** → **Severidad + catálogo ético** → **Popup + evidencia**

La principal mejora arquitectónica frente a la semana 2 es que el sistema ya no depende únicamente del análisis local. Existe una ruta remota pensada para FastAPI y OpenAI, pero el diseño conserva operatividad incluso si el backend no responde, lo cual reduce el riesgo durante la demostración en clase.

4. Cumplimiento de requerimientos del sprint

4.1 Severidad por patrón detectado

Cada patrón detectado incorpora una severidad base definida en rules/detectors.js. En la práctica, esto permite distinguir hallazgos de mayor impacto ético, como false urgency, false scarcity, hidden costs u

obstruction, de otros de impacto medio, como visual interference o misdirection. Además, el popup resume el riesgo agregado de la página en etiquetas como “Riesgo alto”, “Riesgo medio” o “Riesgo bajo”.

4.2 Captura automática del elemento detectado

El popup recorta automáticamente el primer hallazgo priorizado usando captureVisibleTab y las coordenadas rect del elemento visible. Este comportamiento convierte el análisis en algo explicable: no solo se muestra un texto que acusa un patrón, sino también una evidencia visual del punto exacto donde la interfaz genera la señal de manipulación.

4.3 Comparación con catálogo ético

El archivo data/ethical-catalog.json funciona como una capa de trazabilidad ética. Cada id detectado queda asociado a una referencia, una pregunta de revisión y una categoría alineada con el vocabulario de deceptive.design. Esto permite justificar por qué un hallazgo no se reporta solo como “error” o “riesgo”, sino como una posible práctica de presión temporal, escasez manipulada, costos ocultos u obstrucción del flujo.

4.4 Prueba con 5 sitios y validación de precisión

Para cumplir el requisito del sprint, se revisaron manualmente cinco casos principales sobre sitios reales. La validación se consideró correcta cuando la evidencia visible del screenshot y el texto señalado por DarkWatch coinciden con la categoría ética reportada. Los casos ambiguos o con múltiples señales mezcladas se dejaron fuera de la métrica de precisión y se analizaron como evidencia cualitativa complementaria.

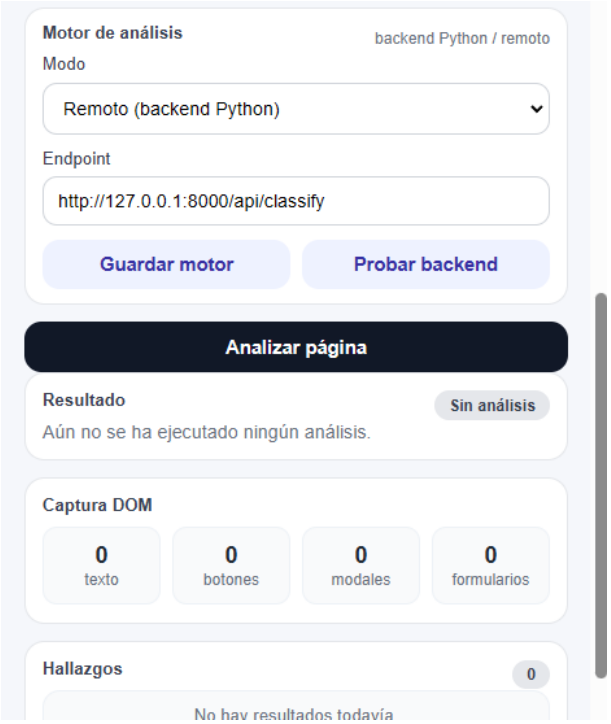

Figura 2. Interfaz del proyecto DarkWatch en modo remoto, con endpoint configurable y resumen de clasificación.

4.5 Señales y categorías consideradas

Patrón	Categoría	Severidad	Referencia ética
Urgencia falsa	Presión temporal	Alta	deceptive.design · urgency
Escasez falsa	Escasez manipulada	Alta	deceptive.design · scarcity
Confirmshaming	Manipulación emocional	Media	deceptive.design · confirmshaming
Suscripción oculta	Cobro recurrente oculto	Alta	deceptive.design · subscription traps
Costos ocultos	Costos tardíos	Alta	deceptive.design · hidden costs
Roach motel	Salida difícil	Media	deceptive.design · roach motel
Preselección engañosa	Default sesgado	Media	deceptive.design · sneaking / preselection
Interferencia visual	Jerarquía visual sesgada	Media	deceptive.design · visual interference
Obstrucción	Bloqueo del flujo	Alta	deceptive.design · obstruction
Misdirection	Desvío de intención	Media	deceptive.design · misdirection

5. Sitios de test y validación manual preliminar

La herramienta se probó en seis sitios reales: AliExpress, Amazon, Temu, eBay, Betano y Viagogo. Esta muestra supera el mínimo de cinco sitios solicitado por la consigna. La validación realizada en este informe no pretende ser una métrica estadística formal, sino una revisión manual preliminar para distinguir aciertos claros, resultados parciales y casos discutibles.

Sitios probados	Coincidencia razonable	Casos discutibles	Precisión preliminar
6	**5**	**1**	**83.3% por sitio**

5.1 Tabla de validación por sitio

Sitio	Salida de DarkWatch	Riesgo	Validación manual preliminar	Resultado
AliExpress	4 hallazgos	Medio	Existe al menos un caso razonable de anclaje de precio; el conjunto todavía mezcla señales plausibles con otras discutibles.	Parcial
Amazon	1 hallazgo	Medio	La alerta sobre costos de importación parece más cercana a transparencia explícita que a costo oculto.	Discutible
Temu	1 hallazgo	Alto	La señal 'quedan 2' y el entorno de oferta limitada encajan claramente con escasez/urgencia.	Confirmado

eBay	1 hallazgo	Medio	La mezcla de bloques patrocinados con resultados orgánicos genera una confusión plausible de contenido.	Confirmado parcial
Betano	1 hallazgo	Medio	El banner de cookies puede obstaculizar el flujo y obliga a gestionar el consentimiento antes de continuar.	Confirmado
Viagogo	1 hallazgo	Medio	La repetición de mensajes de pocas entradas disponibles constituye un caso fuerte de escasez reiterada.	Confirmado

La principal lectura de la tabla es que DarkWatch ya identifica con relativa solidez patrones de presión temporal, escasez y obstrucción. No obstante, la interpretación semántica de precios, descuentos y costos todavía puede producir falsos positivos, sobre todo cuando la interfaz muestra información comercial

6. Evidencia de las pruebas

6.1 Casos 1 y 2: AliExpress y Amazon

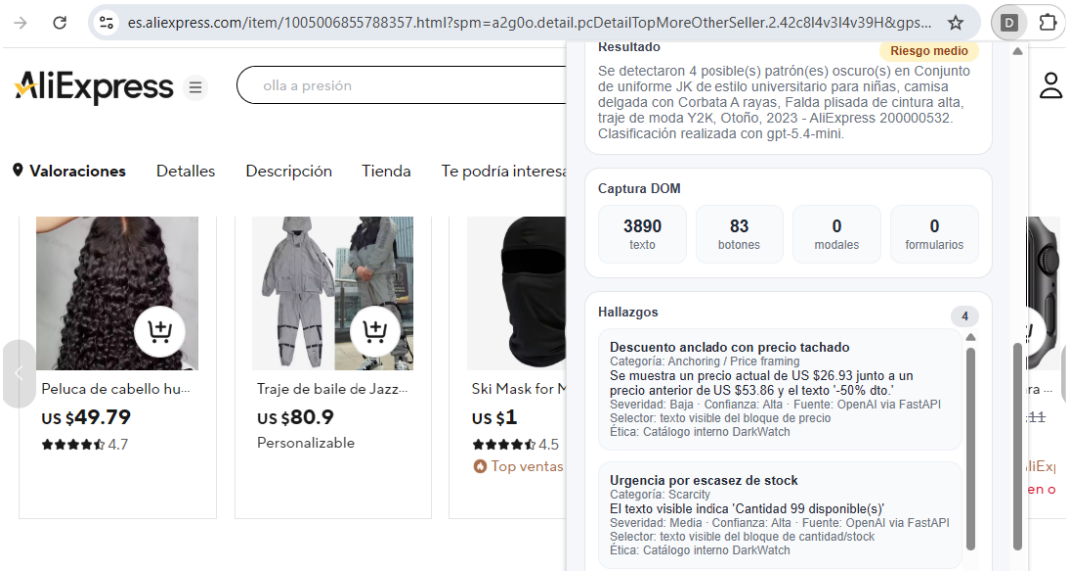

Figura 3. AliExpress: el sistema reporta 4 hallazgos y marca riesgo medio; la revisión manual sugiere un resultado parcial.

Figura 4. Amazon: se reporta un hallazgo asociado a costos, pero la interpretación resulta discutible en la validación manual.

6.2 Casos 3 y 4: Temu y eBay

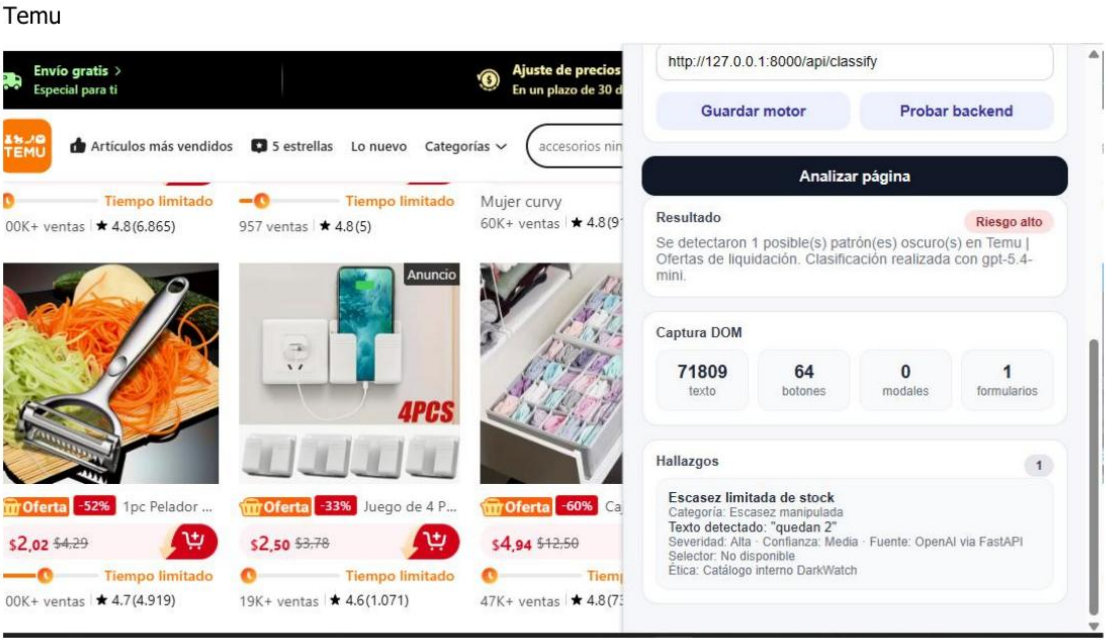

Figura 5. Temu: la escasez explícita ('quedan 2') se alinea con un hallazgo coherente y riesgo alto.

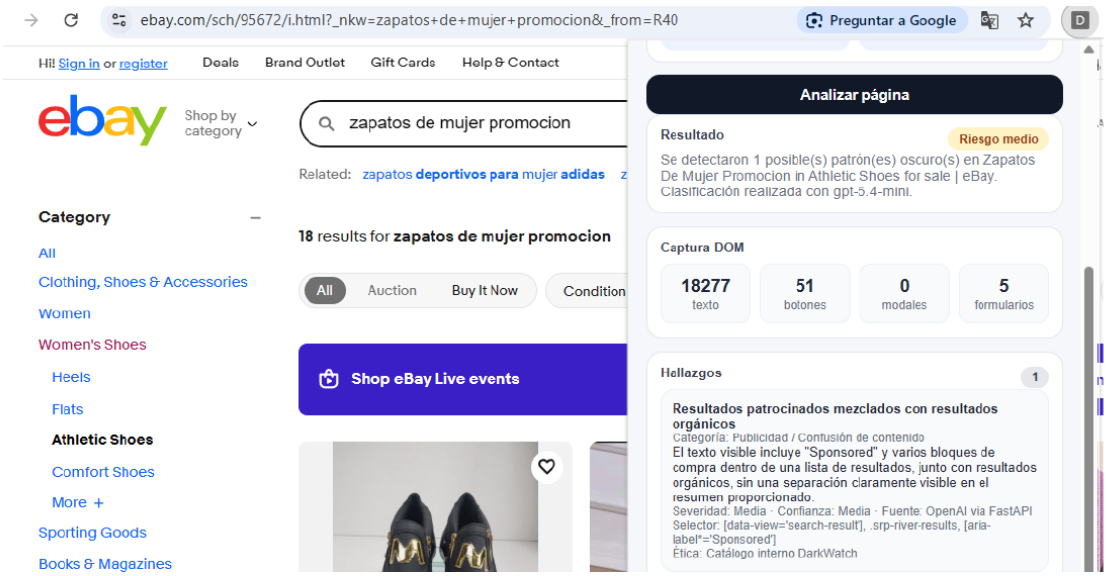

Figura 6. eBay: la mezcla entre resultados patrocinados y orgánicos se interpreta como caso de confusión de contenido.

6.3 Casos 5 y 6: Betano y Viagogo

Figura 7. Betano: el consentimiento de cookies aparece como posible obstrucción del flujo.

Figura 8. Viagogo: la repetición de mensajes sobre baja disponibilidad representa un caso claro de escasez reiterada.

7. Problemas encontrados y decisiones adoptadas

- Falsos positivos semánticos en precios y costos. Decisión adoptada: mantener el caso como evidencia del sprint y dejar explícito que la regla debe refinarse en la siguiente iteración.
- Dependencia de elementos visibles en pantalla. Decisión adoptada: recortar únicamente el primer hallazgo con coordenadas visibles, lo que simplifica la demo, aunque no cubre elementos fuera del viewport.
- Riesgo de caída del backend remoto. Decisión adoptada: implementar un fallback automático al análisis local para que la extensión nunca quede inutilizable durante la prueba.
- Necesidad de separar código sensible del repositorio. Decisión adoptada: no incluir claves ni archivos sensibles del backend en el paquete compartido y centralizar la configuración en un archivo .env del servidor.
- Ambigüedad entre interfaz agresiva y dark pattern confirmado. Decisión adoptada: incorporar validación manual preliminar por sitio, en lugar de asumir que toda salida de la herramienta es correcta.

Estas decisiones muestran que el proyecto ya no se está evaluando solo por si 'funciona', sino por su comportamiento ante errores, por la trazabilidad del resultado y por la capacidad de defender el hallazgo frente a una revisión crítica.

8. Conclusión y siguiente paso

En la semana 3, DarkWatch sí cumple de forma funcional con los objetivos del Sprint 2: ahora reporta severidad por patrón, captura evidencia visual del elemento señalado, compara los hallazgos con un catálogo ético y fue probado manualmente en cinco sitios con una validación preliminar de precisión. El resultado más importante no es solo que “detecta”, sino que explica mejor por qué detecta, en qué parte de la interfaz lo hace y cómo ese hallazgo puede defenderse frente a criterios éticos de diseño.

De cara a la semana final, el proyecto queda listo para crecer hacia un reporte exportable por sitio, una base más amplia de páginas evaluadas y una documentación más rigurosa de falsos positivos y limitaciones. Eso permitirá pasar de una demo funcional a una entrega más sólida y mejor argumentada desde la perspectiva de UX crítica y ética en diseño.