Proyecto 3 - DarkWatch

Informe final - Semana 4: Build empaquetado, publicación y validación de pruebas

Grupo 4: Ariel Aguirre - Edwin Toapanta - Klever Lema

23 de abril de 2026

Resumen ejecutivo

Durante la semana 4, DarkWatch se consolidó como un prototipo académico empaquetable para Chrome. El trabajo se centró en validar el flujo completo: instalación de la extensión, configuración del backend local, ejecución de análisis remoto con modelo LLM, captura de evidencia visual, historial local, exportación de reportes y generación de una base comparativa multi-sitio.

La validación principal registró **25 análisis** sobre **22 sitios únicos**. Los resultados se distribuyeron en **2 casos de riesgo alto**, **13 de riesgo medio** y **10 de riesgo bajo**. En total se registraron hallazgos de severidad **alta, media y baja**, siendo la presión temporal la categoría más frecuente. Por esta razón, la herramienta debe entenderse como apoyo de auditoría y no como reemplazo de la revisión humana.

1. Contexto y objetivo de la Semana 4

La semana 4 corresponde al cierre del ciclo funcional del prototipo. A diferencia de semanas anteriores, donde el foco principal fue construir la extensión y conectar el backend, esta fase se orientó a preparar un entregable demostrable: build limpio, reporte de pruebas, evidencias visuales y explicación de cómo quedaría el proyecto listo para publicación o entrega académica.

Objetivo general

Preparar y validar la versión final del prototipo DarkWatch como una extensión de Chrome lista para ser instalada en modo desarrollador, empaquetada como build académico y documentada mediante pruebas reales sobre sitios con señales de patrones oscuros.

Objetivos específicos

- Verificar que el build contenga solo los archivos necesarios para ejecutar la extensión.
- Ejecutar pruebas en sitios reales y páginas de laboratorio controladas.
- Registrar hallazgos con nivel de riesgo, severidad, categoría y evidencia visual.
- Exportar reportes individuales, base JSON y comparativo multi-sitio.
- Analizar limitaciones y riesgos éticos del prototipo antes de una publicación pública.

2. Alcance del entregable final

Componente	Estado	Descripción
Extensión Chrome	Completado	Interfaz popup, captura DOM, análisis local/remoto, historial y exportación.
Backend local	Completado	Servicio FastAPI disponible en `127.0.0.1:8000` para clasificar señales con el modelo configurado.
Evidencia visual	Completado	Captura del elemento o zona asociada al hallazgo detectado.
Base comparativa	Completado	Exportación JSON multi-sitio y reporte HTML comparativo.
Chrome Web Store	Preparado, no publicado	Se generó build empaquetado; publicación real queda como paso posterior por requerir cuenta de desarrollador y revisión.

3. Metodología de prueba

La prueba se realizó con un flujo de auditoría semi-automático. Primero se cargó la extensión en Chrome, luego se configuró el endpoint local del backend, se ejecutó el análisis de cada sitio y finalmente se exportaron los resultados desde la propia herramienta. El criterio de evaluación no fue afirmar que cada hallazgo sea definitivamente ilegal o malicioso, sino identificar señales de diseño que podrían afectar la autonomía, comprensión o decisión del usuario.

Flujo aplicado

1. Carga de la extensión desde el build empaquetado.
2. Activación del modo remoto para usar el backend local.
3. Prueba de conexión con el backend.
4. Ejecución del botón **Analizar página**.
5. Revisión del resultado: riesgo, captura DOM, evidencia visual y hallazgos.
6. Exportación del reporte individual y del comparativo multi-sitio.

Sitios y páginas evaluadas

Dominio / fuente	Número de análisis
amazon.com	5
deceptive.design	3
udemy.com	3
alibaba.com	2
ebay.com	2
ec.betano.com	2
temu.com	2
viagogo.com	2
buscalibre.ec	1
es.aliexpress.com	1
es.shein.com	1
simplicityuio.com	1

Adicionalmente se ejecutaron pruebas controladas en páginas de laboratorio para confirmar que la herramienta detecta escenarios de urgencia falsa, escasez artificial, prueba social engañosa, confirmshaming, preselección engañosa, renovación automática y obstrucción del flujo.

4. Resultados cuantitativos

Métrica	Resultado
Análisis ejecutados	25
Sitios únicos	22
Riesgo alto	2
Riesgo medio	13
Riesgo bajo	10
Hallazgos con severidad alta	6
Hallazgos con severidad media	20
Hallazgos con severidad baja	7

Resumen por riesgo y severidad

Tipo	Alto / Alta	Medio / Media	Bajo / Baja
Riesgo por análisis	2	13	10
Severidad por hallazgo	6	20	7

Categorías más frecuentes

Categoría	Frecuencia
Presión temporal	11
Bloqueo del flujo	4
Escasez manipulada	2
contenido informativo	1
Misdirection / Confusing Wording	1
Choice Architecture / Obstruction	1
Distraction	1
Deceptive Visual Design / Interstitial-like Ad Styling	1

El patrón dominante fue la **presión temporal**, especialmente en mensajes con contadores, frases como “termina hoy”, “finaliza en…” u ofertas con tiempo limitado. También aparecieron señales de obstrucción por modales, bloqueo de flujo, publicidad integrada y escasez manipulada.

5. Evidencias visuales de las pruebas

Las siguientes capturas provienen del documento de evidencias entregado. Muestran la extensión ejecutándose sobre páginas reales y registrando el resultado del análisis, el número de elementos capturados del DOM, el riesgo estimado, la evidencia visual y los hallazgos detectados.

Figura 1. AliExpress: detección de cuenta regresiva de oferta y clasificación de riesgo medio.

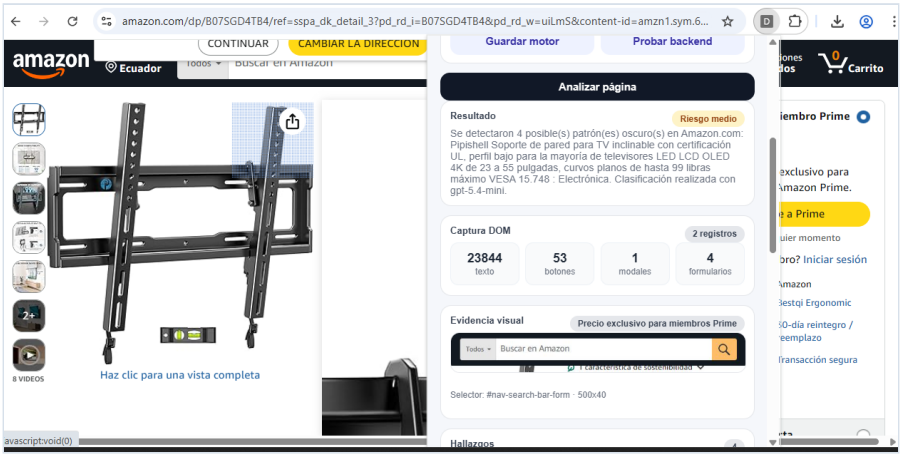

Figura 2. Amazon: detección de precio exclusivo para miembros Prime y señales promocionales.

Figura 3. Amazon producto: posible temporizador de urgencia en oferta.

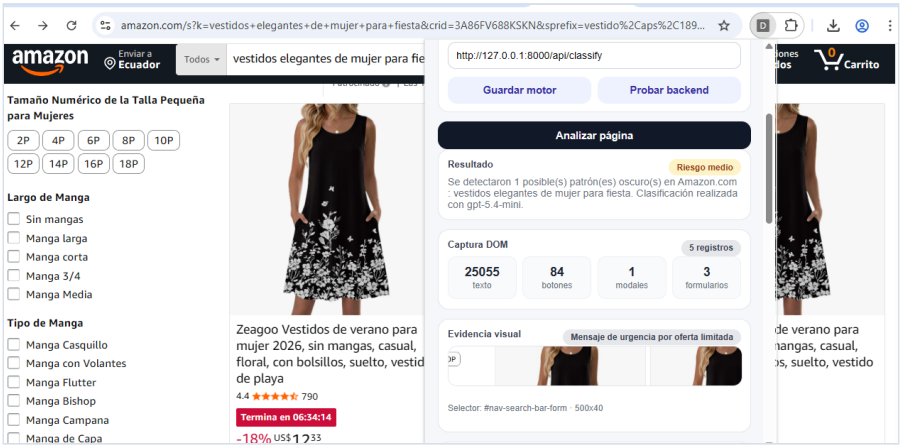

Figura 4. Amazon búsqueda: mensaje de urgencia por oferta limitada en resultados.

Figura 5. Udemy: urgencia temporal persistente en oferta y evidencia visual del temporizador.

Figura 6. Temu: historial reciente con varios sitios analizados y riesgo medio.

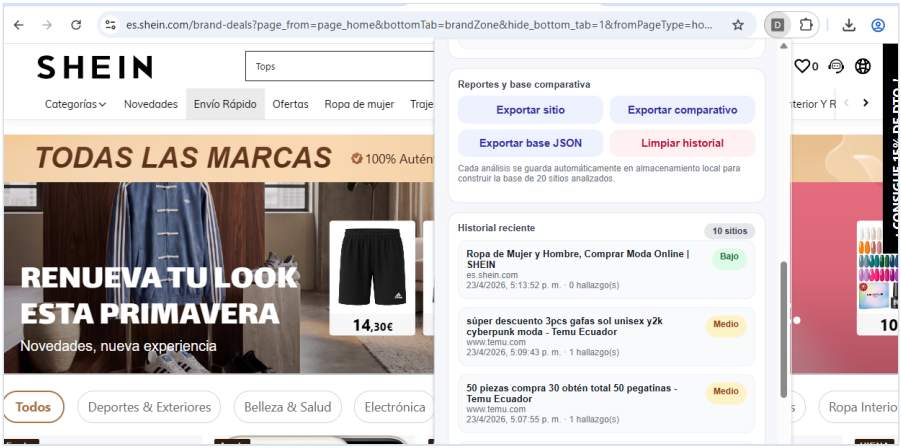

Figura 7. Shein: validación de historial y exportación comparativa desde la extensión.

6. Resultados cualitativos por sitio

A continuación se resume una muestra representativa de los análisis exportados. En los sitios comerciales se observan principalmente señales de presión temporal y escasez. En páginas informativas de deceptive.design se detectaron ejemplos documentados sobre prácticas engañosas, lo que confir-

ma que el motor también puede reconocer contenido descriptivo, aunque este caso debe tratarse con cautela porque no siempre equivale a una práctica activa en la página auditada.

Sitio	Riesgo	Hallazgos	Ejemplo de señal detectada
udemy.com	Medio	2	Texto visible: “Finaliza en 4 h 26 m 55 s. … Termina hoy.” y “Quedan 4 horas a este precio.”
deceptive.design	Bajo	1	La página muestra un listado de artículos y referencias sobre supuestos patrones engañosos de LinkedIn, pero no evidencia directa del DOM de una
deceptive.design	Alto	5	El texto visible indica: “The button labelled ‘No, cancel’ actually means ‘cancel the cancellation’ and causes the user to stay subscribed.” Tamb
deceptive.design	Alto	4	El texto visible describe explícitamente que Yahoo usa ‘trick wording’ y que el botón ‘No, cancel’ en realidad significa cancelar la cancelación,
alibaba.com	Bajo	0	Sin hallazgos relevantes.
alibaba.com	Medio	4	En el resumen aparece el texto visible ‘Envío GRATIS en tu primer pedido’ junto al listado de productos.
simplicityuio.com	Bajo	1	Texto visible: “Pagos seguros Cancela con tu tarjeta preferida sin costos adicionales”
buscalibre.ec	Bajo	0	Sin hallazgos relevantes.
viagogo.com	Medio	2	Se muestra repetidamente texto como “Sólo queda un 2% de las entradas”, “Quedan 2 boletos en este anuncio” y “Éstas son las últimas entradas”.
viagogo.com	Medio	1	Se repiten mensajes como “Sólo queda un 1% de las entradas”, “Quedan 2 boletos en este anuncio” y “Éstas son las últimas entradas” junto a múltip

7. Build empaquetado y preparación para publicación

Para la entrega final se separó el proyecto fuente del build instalable. Esta separación es importante porque un repositorio académico puede conservar documentos, evidencias, reportes y código del backend, mientras que el build de una extensión debe contener únicamente los archivos necesarios para ejecutarse en Chrome.

Elemento	GitHub	Build Chrome	Observación
`docs/` con informes PDF	Sí	No	Útil para evidencias académicas, pero no para instalar la extensión.
`backend/`	Sí	No	Necesario para reproducir el modo remoto, pero no forma parte del paquete de la extensión.
`manifest`, `popup`, `content`, `background`	Sí	Sí	Archivos principales de la extensión.
`data/`, `rules/`, `services/`, `utils/`	Sí	Sí	

Elemento	GitHub	Build Chrome	Observación
			Recursos necesarios para detección y funcionamiento.
`node_modules`, `.venv`, `__pycache__`	No	No	Archivos generados o dependencias locales.
`.env`	No	No	Puede contener claves privadas; usar `.env.example`.

Decisión de publicación

No se publicó públicamente en Chrome Web Store porque el prototipo se encuentra en fase académica y experimental. Sin embargo, el build quedó preparado para cargarse en modo desarrollador o para ser enviado posteriormente a revisión de Chrome Web Store. Esta decisión es responsable, ya que una publicación pública exige revisar privacidad, permisos, política de datos, justificación de permisos y estabilidad del backend.

Carpeta `docs` en GitHub

Sí es adecuado mantener informes PDF dentro de la carpeta `docs` del repositorio académico. Lo recomendable es no mezclar esa carpeta con el ZIP de publicación. En GitHub se pueden conservar los informes Semana 3 y Semana 4, las capturas de evidencia y los reportes generados; en el paquete de Chrome solo deben ir los archivos ejecutables de la extensión.

8. Análisis crítico y limitaciones

- La herramienta identifica señales de riesgo, pero no reemplaza una auditoría humana completa.
- Algunos textos promocionales pueden ser legítimos; se requiere evaluar contexto, disponibilidad real y transparencia.
- El análisis basado en DOM puede perder información renderizada dinámicamente, imágenes o contenido cargado después.
- La clasificación del LLM puede variar según el prompt, el modelo y el contenido visible al momento de la prueba.
- El uso de capturas debe cuidar privacidad: no registrar sesiones personales, datos de cuenta, correos o información sensible.

9. Conclusiones

- DarkWatch logró consolidarse como un MVP funcional para detección inicial de dark patterns en páginas web.

- La semana 4 demuestra un flujo completo: análisis, evidencia visual, historial, exportación y build empaquetado.
- La mayoría de hallazgos se concentró en riesgo medio y en patrones de presión temporal, lo que coincide con prácticas comunes de comercio electrónico.
- El proyecto es válido como herramienta de apoyo académico y de auditoría exploratoria, pero debe mantener supervisión humana para interpretar cada hallazgo.
- La estructura recomendada separa repositorio académico, backend, documentos y build de publicación, reduciendo riesgo de entregar archivos privados o innecesarios.

10. Recomendaciones

- Mantener en GitHub la carpeta `docs` con informes y evidencias, pero excluirla del ZIP para Chrome.
- Agregar una política de privacidad simple si se considera una publicación real.
- Justificar permisos en el manifiesto y reducir `host_permissions` si el flujo final lo permite.
- Aumentar el set de pruebas con más sitios y registrar falsos positivos y falsos negativos.
- Mejorar la trazabilidad de cada hallazgo: selector, texto, categoría ética, severidad y captura asociada.

Archivos revisados para este informe

- `Informe_DarkWatch_Semana3.pdf`: referencia de formato.
- `Semana4.docx`: fuente de evidencias visuales.
- `DarkWatch.zip` y `DarkwatchTest.zip`: fuentes de reportes exportados y base comparativa JSON.